

# ch4. 피셔 추론과 최대 우도 추정

Ji Seung Ryu

7월 10, 2019

## 4.1 우도와 최대 우도

### Likelihood(우도)

- $(X_1, X_2, X_3, \dots, X_n) \sim f(x_1, x_2, x_3, \dots, x_n | \theta), \theta \in \Omega$
- $L(\theta | x_1, x_2, x_3, \dots, x_n) = f(x_1, x_2, x_3, \dots, x_n | \theta), \theta \in \Omega$   
=  $L_X(\theta)$  for brevity,  $\theta \in \Omega$
- $l_X(\theta) = \log\{f_\theta(x)\}$

관측치  $x$ 가 고정된 상태에서 모수  $\theta$ 가 변화된다.

단일 값일 경우에는  $\theta$ 를 사용하고 모수 벡터일 경우에는  $\mu$ 를 사용한다.

확률 밀도 함수를 랜덤변수의 값  $x$ 의 함수가 아닌 파라미터  $\theta$ 의 함수로 보는 것

확률 분포로부터 특정한 샘플 값  $x$ 가 발생하였을 때, 이 샘플 값  $x$ 가 나오게 하는 파라미터  $\theta$ 의 가능성

확률 분포로부터 특정한 샘플 값  $x$ 가 발생하였을 때, 샘플 값  $x$ 와 변수  $\theta$ 에서의 확률(밀도함수)

### 확률 밀도 함수

$$f_X(x; \theta)$$

- $\theta$  값을 이미 알고 있음
- $\theta$ 는 상수,  $x$ 는 변수
- $\theta$ 가 이미 정해져 있는 상황에서의  $x$  값의 상대적 가능성

### Likelihood(우도)

$$L(\theta) = f_X(x | \theta)$$

- $x$ 가 이미 발생. 값을 이미 알고 있음
- $x$ 는 상수,  $\theta$ 는 변수
- $x$ 가 이미 정해져 있는 상황에서의  $\theta$  값의 상대적 가능성

### MLE(최대 우도 추정)

로그 우도 함수 =  $\log L_\theta(x)$

보통 계산하기 간편한 로그 우도함수를 많이 사용한다.

$$MLE : \hat{\theta} = \operatorname{argmax}_{\theta \in \Omega} l_x(\theta)$$

MLE란 모수 공간  $\Omega$ 에서  $l_x(\theta)$ 를 최대화 하는  $\theta$  값이다.

**1. 최대 우도 추정은 전통적 응용 추정에서 대세적인 기법이며, 새로운 현상을 접할 때 가장 먼저 적용해보는 기법이다.**

- MLE알고리즘은 자동화되어 있다.
- MLE는 빈도주의가 가진 뛰어난 성질을 잘 활용한다.(대규모 표본 : 불편 추정치, 최소한의 분산 / 소규모 표본 : 효율적, 최상위급 성능)
- MLE는 베이즈주의 정당성을 가지고 있다. (베이즈 방식에서 사전함수가 균등, 상수일 경우)

**2. 최대 우도 추정에서는 개별적으로 최대 우도는 잘 구하지만 다차원일 경우에는 잘못 구해질 수 있다.**

- 전립선 예제

## 4.2 피셔 정보와 MLE

### 단일 모수 밀도 패밀리

$$MLE : \hat{\theta} = \operatorname{argmax}_{\theta \in \Omega} \{l_x(\theta)\}$$

$$F = \{f_{\theta}(x), \theta \in \Omega, x \in X\}$$

$$\text{스코어 함수 } \dot{l}_x(\theta) = \frac{\partial}{\partial \theta} \log f_{\theta}(x) = \frac{\dot{f}_{\theta}(x)}{f_{\theta}(x)} \text{ (점 표기는 미분을 뜻한다.)}$$

$$E(\dot{l}_x(\theta)) = 0, \operatorname{Var}(\dot{l}_x(\theta)) = I_{\theta} \text{ (정의)}$$

$$\text{즉, } \dot{l}_x(\theta) \sim (0, I_{\theta}) \Rightarrow MLE \hat{\theta} \sim N(\theta, 1/I_{\theta})$$

$\hat{\theta}$ 의 분산이  $1/I_{\theta}$ 에 근사하는 것 증명 - The asymptotic distribution of MLE

([http://people.missouristate.edu/songfengzheng/Teaching/MTH541/Lecture%20notes/Fisher\\_info.pdf](http://people.missouristate.edu/songfengzheng/Teaching/MTH541/Lecture%20notes/Fisher_info.pdf))

$\theta$ 는 거의 불편함이고 큰 피셔정보라는 것은 더 작은 MLE분산을 암시한다.

$$\ddot{l}_x(\theta) = \frac{\partial^2}{\partial \theta^2} \log f_{\theta}(x) = \frac{\ddot{f}_{\theta}(x)}{f_{\theta}(x)} - \left(\frac{\dot{f}_{\theta}(x)}{f_{\theta}(x)}\right)^2$$

$$E_{\theta}\{\ddot{l}_x(\theta)\} = -I_{\theta}, \operatorname{Var}_{\theta}\{\ddot{l}_x(\theta)\} = J_{\theta}$$

$$\text{즉, } \ddot{l}_x(\theta) \sim (I_{\theta}, J_{\theta})$$

### iid 표본의 예

$$x = (x_1, x_1, \dots, x_n) \sim^{iid} f_{\theta}(x)$$

$$\dot{l}_x(\theta) = \sum_{i=1}^n \dot{l}_{x_i}(\theta)$$

$$-\ddot{l}_x(\theta) = \sum_{i=1}^n -\ddot{l}_{x_i}(\theta)$$

전체 표본  $x$ 에 기반한 MLE  $\theta$ 는 최대화 조건  $\dot{l}_x(\hat{\theta}) = 0$ 을 만족한다.

$$\text{일차 테일러 급수} : \hat{\theta} \doteq \theta + \frac{\dot{l}_x(\theta)/n}{-\ddot{l}_x(\theta)/n}$$

$$\text{중심극한정리} : \dot{l}_x(\theta)/n \sim N(0, I_\theta/n)$$

$$\text{Var}(\sum_{i=1}^n \dot{l}_x(\theta)/n) = \frac{1}{n^2} n \text{Var}(\dot{l}_x(\theta)) = \frac{1}{n} \text{Var}(\dot{l}_x(\theta)) = I_\theta/n$$

$$\text{대수의 법칙} : -\ddot{l}_x(\theta)/n \sim I_\theta$$

$$E(\sum_{i=1}^n -\ddot{l}_x(\theta)/n) = \frac{1}{n} n E(-\ddot{l}_x(\theta)) = E(-\ddot{l}_x(\theta)) = I_\theta$$

즉, iid 대규모 표본에서는  $\hat{\theta} \sim N(\theta, 1/(nI_\theta)) \Leftarrow$  iid 표본의 전체 피셔 정보는  $nI_\theta$

## 정규 표본의 예

$i = 1, 2, \dots, n$ 에 대해  $x_i \sim^{iid} N(\theta, \sigma^2)$

$$\text{만약 } \sigma^2 \text{를 알 수 있다면, } l_x(\theta) = -\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \theta)^2}{\sigma^2} - \frac{n}{2} \log(2\pi\sigma^2)$$

$$\dot{l}_x(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \theta) \text{이고 } -\ddot{l}_x(\theta) = \frac{n}{\sigma^2}$$

$$\text{즉, } \hat{\theta} \sim N(\theta, \sigma^2/n) \Leftarrow I_\theta = 1/\sigma^2$$

- 피셔의 주된 전술은 논리적으로 복잡한 추론 문제를 간단한 형태로 줄여서 누구에게나 명백한 답을 찾는 것이었다.
- 단일 스칼라 관측치  $\hat{\theta}$ 가 미지의 관심 대상인 모수인  $\theta$  근처를 알려진 분산  $\sigma^2/n$ 으로 정규분포하도록 만드는 것이다.

## 크레이머-라오 경계

$$\text{Var}_\theta\{\hat{\theta}\} \geq 1/(nI_\theta)$$

코시 슈바르츠 부등식에 의해 증명됨

MLE는 적어도  $\theta$ 의 최적 불편 추정만큼 작은 분산을 가진다.

더 자세히 알아보시다 ([http://m.blog.daum.net/gongdjin/122?np\\_nil\\_b=2](http://m.blog.daum.net/gongdjin/122?np_nil_b=2))

## 4.3 조건부 추론

### 간단한 예제

다음의  $x_i \sim^{iid} N(0, 1), i = 1, 2, \dots, n$  iid 표본이 추정치  $\hat{\theta} = \bar{x}$ 를 생성했다.

표본크기  $n$ 에 대한 의견에 서로 동의하지 못해서 동전을 던져서 결정하기로 했다.

$$n = \begin{cases} 25 & \text{확률 } 1/2 \\ 100 & \text{확률 } 1/2 \end{cases}$$

등전 던지기 결과  $n = 25$ 가 선정.

여기서!  $\bar{x}$ 의 표준편차는 얼마일까?

조건부 추론의 추종자 :  $1/(25)^{0.5} = 0.2$

빈도주의 추종자 :  $\bar{x}$ 는 동일한 확률로  $N(0, 1/100)$  또는  $N(0, 1/25)$ 가 될 수 있기 때문에 표준편차는  $[(0.01 + 0.04)/2]^{0.5} = 0.158$

## 피셔가 조건부 추론을 주장하는 근거 : 좀 더 연관된 추론, 더 간단한 추론

- 최대 우도의 정확도 :  $nI_{\theta}$ 보다  $I(x)$ 를 이용하는 것이  $\hat{\theta}$ 에 더 정확한 결론을 안겨준다. ex) 코시밀도 시뮬레이션(조건화 + 경험적 분산)

## 4.4 순열과 랜덤화(Permutation Test 순열검정법)

- 피셔가 직면한 비판 : 정규분포 표본이라는 가정에 지나치게 의존하고 있다.
- 피셔는 순열과 랜덤화를 주장

ex) 유전자 페어링 예제

귀무가설 : A와 B집단이 차이가 없다.

아이디어 : 만약, A와 B집단에 차이가 없다면 A집단과 B집단을 무작위로 섞어도 차이가 없을 것이다.

[R 예시] <https://bioinformaticsandme.tistory.com/10> (<https://bioinformaticsandme.tistory.com/10>)